面向股票截面预测的约束驱动模型搜索与训练方法

跨年验证、动态剪枝与受限增量学习

Shihan Zhao

2026 年 10 月 16 日

摘要

低信噪比与时变分布使股票预测面临双重挑战：模型需要从有限数据中提取有效信息，研究者也需要在反复搜索中控制选择偏差。本文以沪深 300 短期截面预测为案例，归纳一套约束驱动的模型搜索与训练方法：按标签成熟时间划分训练样本，以跨年匹配比较评价增量，逐级筛选候选，并通过受限修正和原始输入复算衔接训练与部署。最终模型 FNR（Factor Neighborhood Ranker，因子邻域排序模型）在公榜取得平均秩信息系数（RankIC）0.0850、组合信息比率（IR）5.5684，总成绩排名第 2；在私榜取得 RankIC 0.0825、IR 5.2132，总成绩排名第 1。两项指标相对公榜分别仅回落 2.94% 和 6.38%，为固定方案在额外隐藏评价中的表现提供了证据。结合候选淘汰记录和局部对照，本文分析各项约束如何影响研究决策，并讨论反复使用开发数据所带来的选择偏差及其验证需求。

关键词：时间验证；模型选择；自适应搜索；增量学习；选择偏差；截面预测

1 引言

本研究以沪深 300 指数增强与截面选股比赛为背景。参赛者利用历史行情、公司基本面和风险因子，比较同一交易日的沪深 300 成分股，判断哪些股票在下一个交易周期内更可能表现较好，并为每只股票生成预测分数。组织方通过统一的组合构建和回测程序，将分数转化为投资配置，在控制相对指数的风险偏离和交易成本的条件下，争取获得超过沪深 300 指数的收益。评分同时考察排序精度与组合收益。

模型研究还包含持续的方案选择：变量、结构、训练目标的选择以及候选的去留，都依赖已有评价结果。反复搜索可能放大偶然优势，排序指标的提升也未必转化为组合收益。本文关注如何识别可靠增量：在一致的时间边界与评价条件下比较候选，用跨年表现约束局部优势，并将有效改动落实为可复现的部署模型。

Cawley 与 Talbot[1] 指出，反复优化模型选择准则会造成选择偏差。Dwork 等 [2] 研究自适应复用数据的统计有效性，说明先前评价如何影响后续检验。这些工作提示，解释最终模型的表现时，需要同时考察其选择过程，并以未参与该轮选择的数据进一步检验。

有限计算预算下，Hyperband[3] 通过逐级分配资源提高超参数搜索效率，为尽早终止较差候选提供了可借鉴的机制。预测器内部则可通过结构与正则控制拟合自由度：LightGBM[4] 用提升树刻画表格数据关系，TabM[5] 以共享参数实现神经集成，岭回归 [6] 通过收缩系数稳定估计，成对排序损失 [7] 直接学习相对顺序。本文以这些方法为构件，检验其在截面预测中的增量价值。

针对上述问题，本文将模型研究组织为约束驱动的搜索与训练流程。训练样本按标签成熟时间划分，历史成员与预处理统计遵循当时可见的信息，以控制泄漏风险；候选通过跨年匹配比较逐级筛选，减少对单一时期的依赖。模型采用集成、收缩和受限修正控制噪声响应，并结合长期预测与近期统计适应市场变化。部署前重新加载权重、从原始窗口复算预测，以核对研究和部署的一致性；方案固定后再接受私榜评价。FNR 在公榜取得 RankIC 0.0850、IR 5.5684，

总成绩排名第 2；在私榜取得 RankIC 0.0825、IR 5.2132，总成绩排名第 1。下文依据保存的实验与搜索记录，分析这些措施如何影响候选取舍，并讨论最终结果所支持的结论。

上述搜索与训练方法在研究者与大语言模型（LLM）的持续对话中迭代形成。研究者设定目标与约束，结合评价反馈判断研究方向；LLM 参与文献分析、假设提出、实验设计与结果分析，并编写代码、调用工具，执行数据处理、特征构造、模型训练、回测、候选剪枝、日志记录和部署核验。实验结果进一步用于修订研究方案，推动方法逐步完善。本研究使用 GPT-6 Astra 与 GPT-6.1 Sol，累计 token 用量 1B。

2 约束驱动的搜索与训练方法

2.1 研究流程与比较基础

研究流程包含四个环节：约定信息与评价口径、生成并筛选候选、冻结模型、进行隐藏评价（图1）。每批实验须先固定允许输入、标签和比较条件，再明确候选相对参考对象的改动及停止条件。候选通过筛选后进入完整比较和部署确认，下一批实验则根据当前结果调整方向。

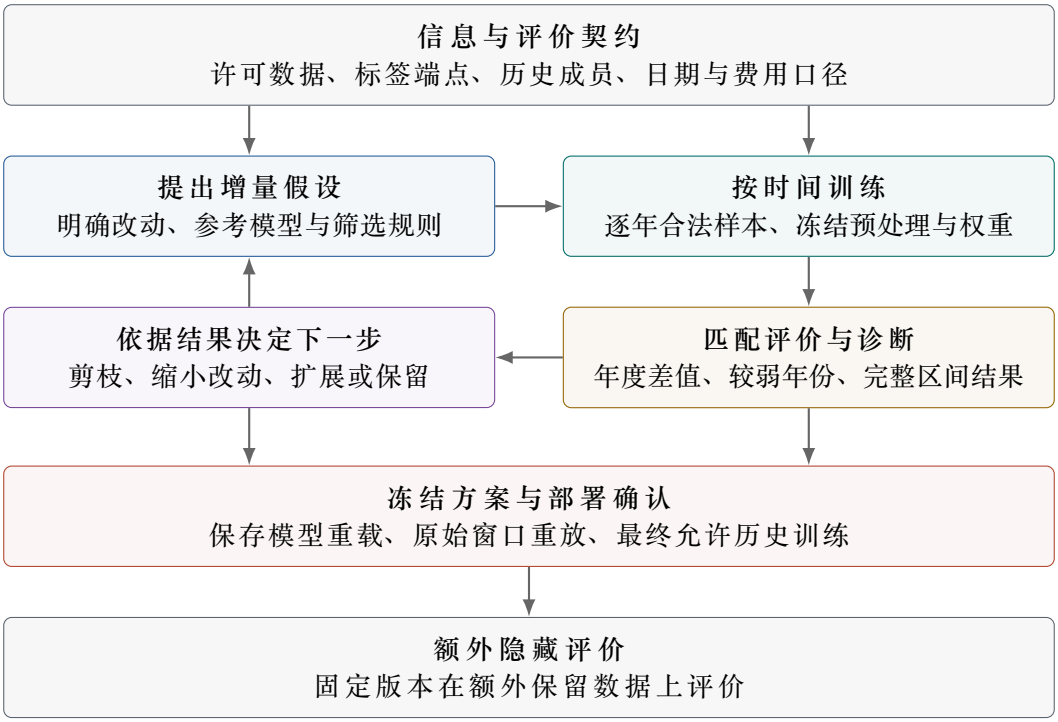


图 1: 模型搜索与训练流程。开发评价用于选择候选，固定方案接受额外隐藏评价。

研究记录包括各候选的配置、父模型、输入日期、有效样本、训练资源与运行状态。失败与被剪枝候选的配置和运行记录同样存档，缺失指标与已完成的年度评价分别标注，便于复核选择依据。

2.2 时间边界与年度向前验证

令交易日 t 的可见股票集合为 $\mathcal{U}_t$。模型在 t 日收盘后生成对以下收益的预测：

$$y_{i,t} = \frac{O_{i,t+2}}{O_{i,t+1}} - 1, \qquad H = 1, \tag{1}$$

其中 O 为官方复权开盘价，下标按市场交易日历推进。标签成熟表示其收益终点已发生，计算所需价格已可见。评价年 Y 的训练集合要求

$$\mathcal{D}_Y^{\text{train}} = \{(i,t) : \text{exit}(y_{i,t}) < \text{start}(Y)\}. \tag{2}$$

例如，12 月末的信号若需要下一年开盘价才能完成标签，应从新年验证模型的训练样本中排除。

同一候选在各年度保持相同结构与超参数，使用对应训练期的数据重新估计权重和预处理参数。部署版本在方案确定后，使用部署起点之前的全部允许历史重新训练。

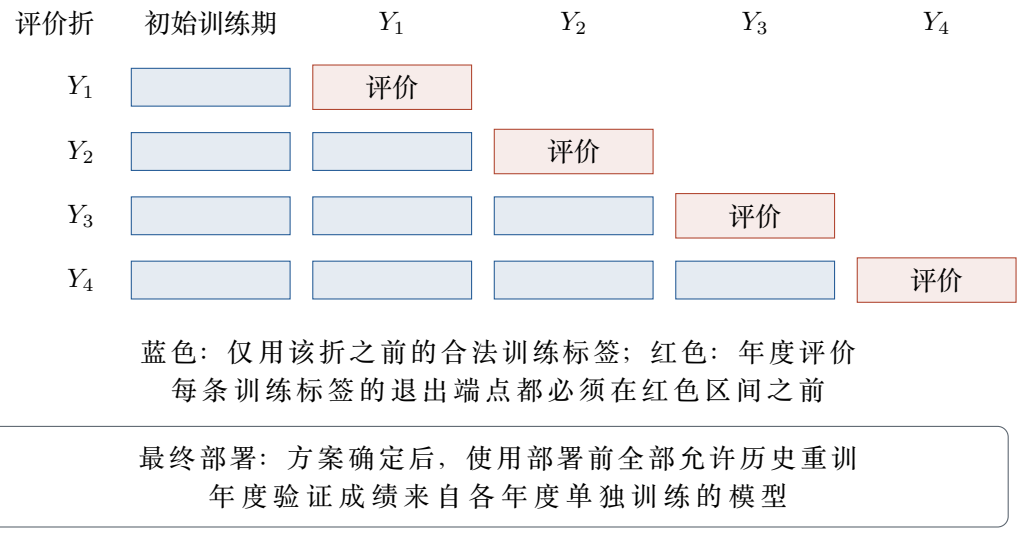


图 2: 扩展窗口的年度向前验证。每个评价期使用更早的数据训练，边界按标签退出时间划分；滚动训练窗口也遵循这一要求。

缺失值填补所需的统计量、均值与标准差、数值特征分段编码的分位节点及统计先验，均在对应训练期内估计。历史截面的股票池与邻域依据当时可见信息构建；标签成熟后，再确定损失和事后指标的有效样本。

年度训练边界按标签退出时间切分，避免跨期标签进入训练；多个评价期共同检验配置的稳定性。反复用于模型选择的区间按开发数据处理，方案固定后再进入额外评价。

2.3 排序、组合与成本的评价口径

平均 RankIC 先计算同日预测分数与真实收益的 Spearman 秩相关，再按有效日期等权平均，用于衡量横截面上的排序能力。组合 IR 衡量相对基准的主动收益与跟踪误差之比。令组合和基准的日收益分别为 r_t^p, r_t^b，主动收益为 $e_t = r_t^p - r_t^b$，本地回测采用 skd-backtest 框架 [8]，IR 的计算口径为

$$\text{IR} = \frac{R_{\text{ann}}^p - R_{\text{ann}}^b}{\sqrt{252}\,\text{sd}_{\text{sample}}(e_t)}, \tag{3}$$

其中年化收益由净值复合计算，分母为主动收益的年化波动，即跟踪误差。完整区间的 IR 需要从该区间净值与主动收益序列重新计算。

同一轮比较须固定日期、标签、有效样本、组合约束与成本口径。佣金与滑点按实际成交额计入现金流，并以较高成本情景检验敏感性。组合约束统一规定多空方向、仓位、个股权重、相对基准偏离、风险暴露与换手上限。

年度独立账户与跨期连续账户的指标分别计算、分别报告。比较候选与参考模型时，须保持相同账户口径，并核对成交、净值衔接与跨年仓位处理。仅评价排序的实验与不同成本情景分别标注。

2.4 增量归因：区分信息、表示与学习器

设候选 c 在年份 Y 的训练结果为 $\theta_{c,Y} = \mathcal{A}(\mathcal{D}_Y^{\text{train}}; c)$，候选 c 由特征、标签、学习器与训练配置共同定义。在相同日期集合上，计算其相对参考模型 b 的增量：

$$\Delta_{c,Y} = \text{MeanRankIC}(c, Y) - \text{MeanRankIC}(b, Y). \tag{4}$$

通过固定其余条件，可以将差值归因于被改变的因素；同时改变特征和学习器时，差值反映二者的联合效果。

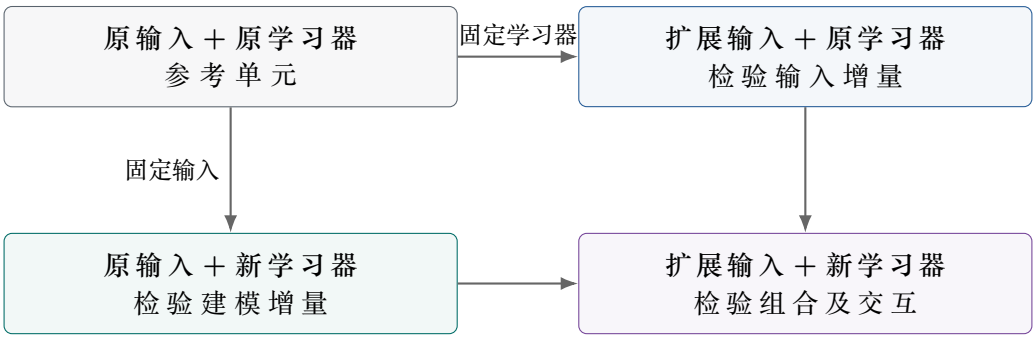


图 3: 输入与学习器的匹配比较设计。学习表示的评价还需计入上游教师的输入、模型容量与训练成本；实际完成的比较以实验记录为准。

输入扩展、手工因子、监督学习表示和学习器改变分别组织对照。输入实验固定模型容量与训练目标，学习器实验固定输入与目标；在有互补证据后，再检验联合配置。

监督学习表示还需核对上游标签的使用范围。折外教师由未见当前样本标签的模型生成特征；同一训练期内依次训练表示与下游模型时，则将其作为分阶段训练评价，并检查样本内表示偏差。

2.5 候选提议、逐级评价与动态剪枝

研究者围绕可检验假设提出候选，例如平滑强度对排序与换手的影响、收益残差目标的增量价值，以及潜在因子数量对跨年稳定性的作用。每批仅改变少量关键因素，再根据结果调整强度、扩展局部搜索或终止该方向。

对一批候选，进入下一轮的条件可写为

$$G(c) = \mathbf{1}\{\Delta_{c,Y} \geq -\epsilon_Y \ \forall Y \in \mathcal{Y}, \quad \Delta_{c,\text{pooled}} \geq \eta\}, \tag{5}$$

其中 ϵ_Y 为该轮允许的年度回退，η 为合并增量门槛，均按当轮研究目标设定。涉及组合表现时，还需加入年度或连续账户的 IR 条件。上述阈值用于候选选择；相应的选择偏差与验证需求在第4.2节讨论。

较弱年份用于低成本初筛，通过者再完成其余年份。每一搜索轮次都记录各候选的训练轮数、已评价年份和完成状态。训练轮数须预先固定，或仅通过训练期内部验证选择；年度评价标签用于比较已训练候选。

剪枝将计算资源集中到较有希望的候选，跨年门槛则要求增益覆盖多个时期。随着候选增加，研究也会更充分地利用开发数据中的偶然规律，因此所选方案仍需接受独立于该轮选择的评价。

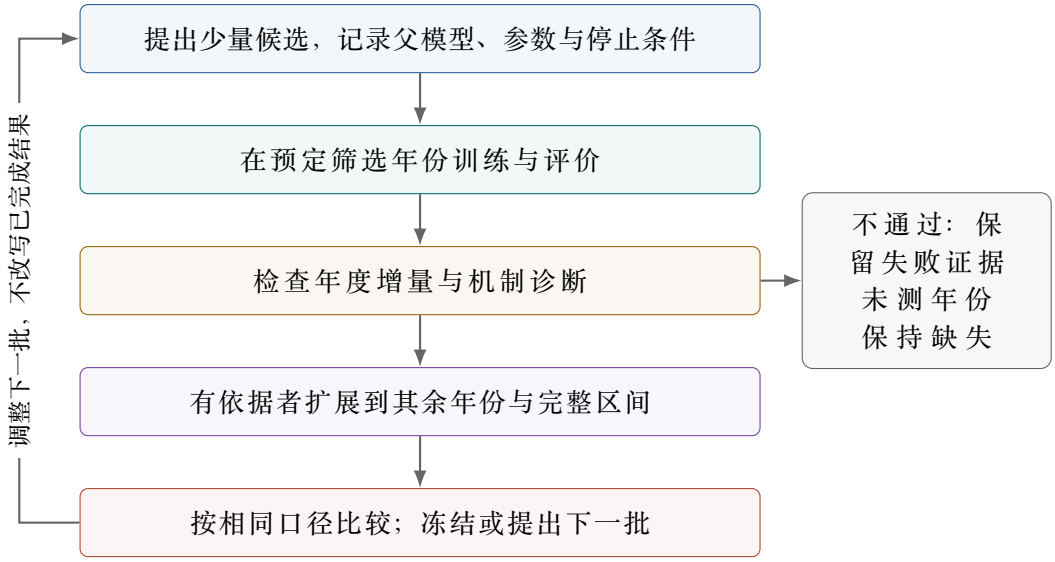


图 4: 逐级评价与动态剪枝。较弱年份用于初筛，通过者完成全部年份的评价。

2.6 受限增量训练

以已验证的参考预测为起点，新增模块采用受限增量形式

$$s_{i,t} = s^0_{i,t} + \delta_{i,t}, \qquad u_{i,t} = c_\delta \tanh f_\phi(z_{i,t}), \qquad \delta_{i,t} = u_{i,t} - \frac{1}{N_t}\sum_j u_{j,t}. \tag{6}$$

s^0 是参考预测，z 是既有表示或其扩展，ϕ 为新增参数，N_t 为当日股票数，c_δ 为固定限幅常数。输出层零初始化使初始增量为零。保持项持续惩罚对参考预测的偏离，拟合误差的下降需要补偿这项代价。限幅作用于去均值前的输出 $u_{i,t}$，因此单只股票满足 $|\delta_{i,t}| \le 2c_\delta$，任意两只股票满足 $|\delta_{i,t} - \delta_{j,t}| \le 2c_\delta$。

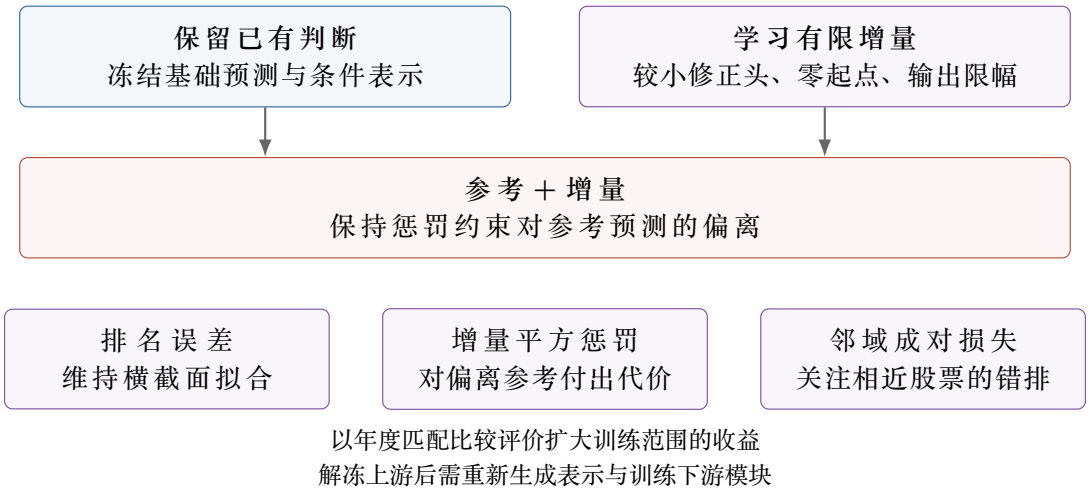


图 5: 受限增量训练：排名与配对损失学习新增信息，保持惩罚约束对参考预测的偏离。

对应的一类训练目标为

$$\mathcal{L} = \mathcal{L}_{\text{rank}} + \lambda \mathcal{L}_{\text{preserve}} + \gamma \mathcal{L}_{\text{pair}}. \tag{7}$$

排名误差学习同日相对位置，保持项惩罚增量平方，配对项学习相近股票的收益顺序，并对收益差距采用有上限的权重。保持强度与配对权重通过匹配对照选择，组合表现由训练后的回测评价。

其他约束包括训练期标准化、按日期归一化权重、权重衰减、Dropout、固定训练轮数和低秩共同因子结构。共同因子描述多只股票的同步变化，低秩结构限制此类变化方向的数量。排名标签减弱极端收益幅度的影响，原值特征和收益差距加权保留部分幅度信息。异构学习器与不同标签的集成则利用预测误差的差异，争取降低估计波动。

分层解冻和全参数解冻扩大了可训练范围。评价这类改动时，需要核对实际可训练参数，重新生成年度表示与邻域，并重训依赖它们的下游网络。上游表示改变后，需同步更新预测缓存，即为后续比较保存的中间表示和预测结果。最终以候选相对参考模型的年度表现决定取舍。

2.7 长期参照与受限近期适应

已实现收益可用于补充长期预测。对信号日 t，按标签式(1)，可使用的历史信号满足 $s+2 \leq t$；从许可历史窗口内选取最近 m 个此类截面，构成 $\mathcal{S}_t$。窗口长度、特征维数和时间权重在离线阶段固定。

令 $z_{i,s}$ 为历史股票特征，$v_{i,s}$ 为预先确定的收益目标，$a_{i,s}$ 为截面样本权重，构造 $A_s = \sum_i a_{i,s} z_{i,s} z_{i,s}^{\mathsf{T}}$ 与 $b_s = \sum_i a_{i,s} z_{i,s} v_{i,s}$。给定先验系数 β_0、惩罚矩阵 P 及日期权重 w_s，当前窗口的回归系数为

$$\widehat{\beta}_t = (\sum_{s \in \mathcal{S}_t} w_s A_s + P)^{-1} (\sum_{s \in \mathcal{S}_t} w_s b_s + P\beta_0). \tag{8}$$

模型权重、先验系数 β_0、惩罚矩阵 P、日期权重及统计规则均在离线阶段确定。当前窗口内的样本用于计算临时系数，进而生成增量分数；历史输入在每次预测时重建。低维表示、先验收缩与输出限幅共同约束短期噪声的影响。

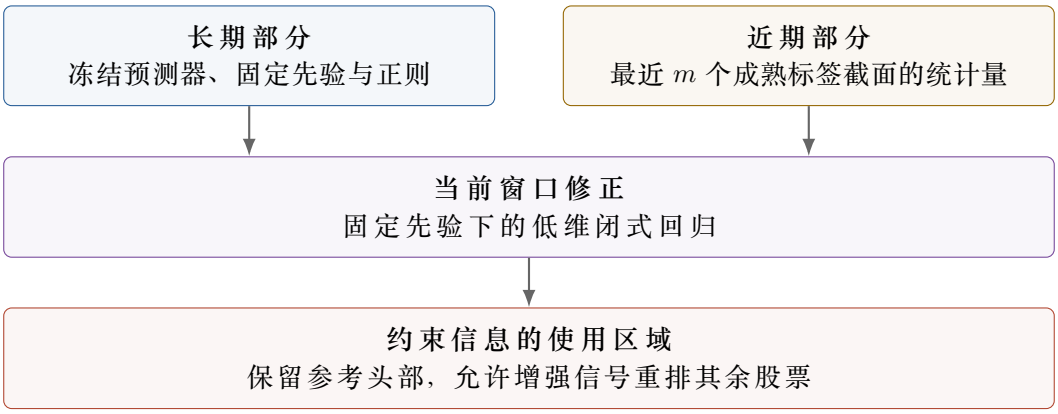


图 6: 近期信息的使用方式：固定先验、窗口统计校正与排序范围约束共同控制调整幅度。

近期增量可进一步限制在预先指定的排序区域内：保留参考模型的头部名单与顺序，仅重排其余股票。保留范围通过匹配比较确定，使信息利用强度成为可检验的变量。对持仓与收益的影响仍由同一组合构造规则评价。

2.8 从研究结果到可执行模型的确认

搜索阶段利用预测缓存加速比较。部署确认时，重新加载保存的权重，从原始输入计算特征与预测，并核对输入输出格式、数值导出结果及资源占用。年度模型用于对应年份的评价，部署模型使用部署前全部允许历史训练。

预测缓存上的评价与原始输入复算出现差异时，应追查特征重建、浮点精度导致的并列排名及导出实现等来源，并以实际部署路径的复算值报告结果。复现记录注明完整流程重训、局部重训和输入输出检查各自覆盖的范围。

3 方法的应用与实证结果

3.1 评价设置与模型关系

本地开发使用 2016–2022 年公开数据，按第2.2节的时间边界逐年训练，评价 2019–2022 年。四个年度均参与了模型选择，所报告的本地结果用于描述开发期表现。最终部署模型使用全部允许历史，训练标签最晚退出日期为 2022 年 12 月 30 日。模型输入仅来自比赛许可的行情、因子和风险数据，行情回看控制在 120 个交易日以内。

组合评价采用第2.3节定义的 IR。基准成本为单边 3bp 佣金加 2bp 滑点，压力情景为 3bp 加 7bp；组合优化器要求仅做多、目标满仓，单股权重上限为 10%，主动权重偏离上限为 1%，行业与风格偏离上限各为 2%。每次调仓的双边权重变化总量满足 $\sum_i |w_i^{\text{target}} - w_i^{\text{current}}| \le 1.0$，股票池外持仓的清仓也计入其中。早期零成本诊断和后续含成本结果在表中分别注明，年度 IR 逐年报告。平台完整组合配置未披露。

模型研究从输入与学习器比较，逐步转向因子表示、相对收益修正和近期信息利用。图7与表1给出主要候选的关系和成绩；下文按研究假设组织对照，说明每一阶段如何应用第2章的方法。

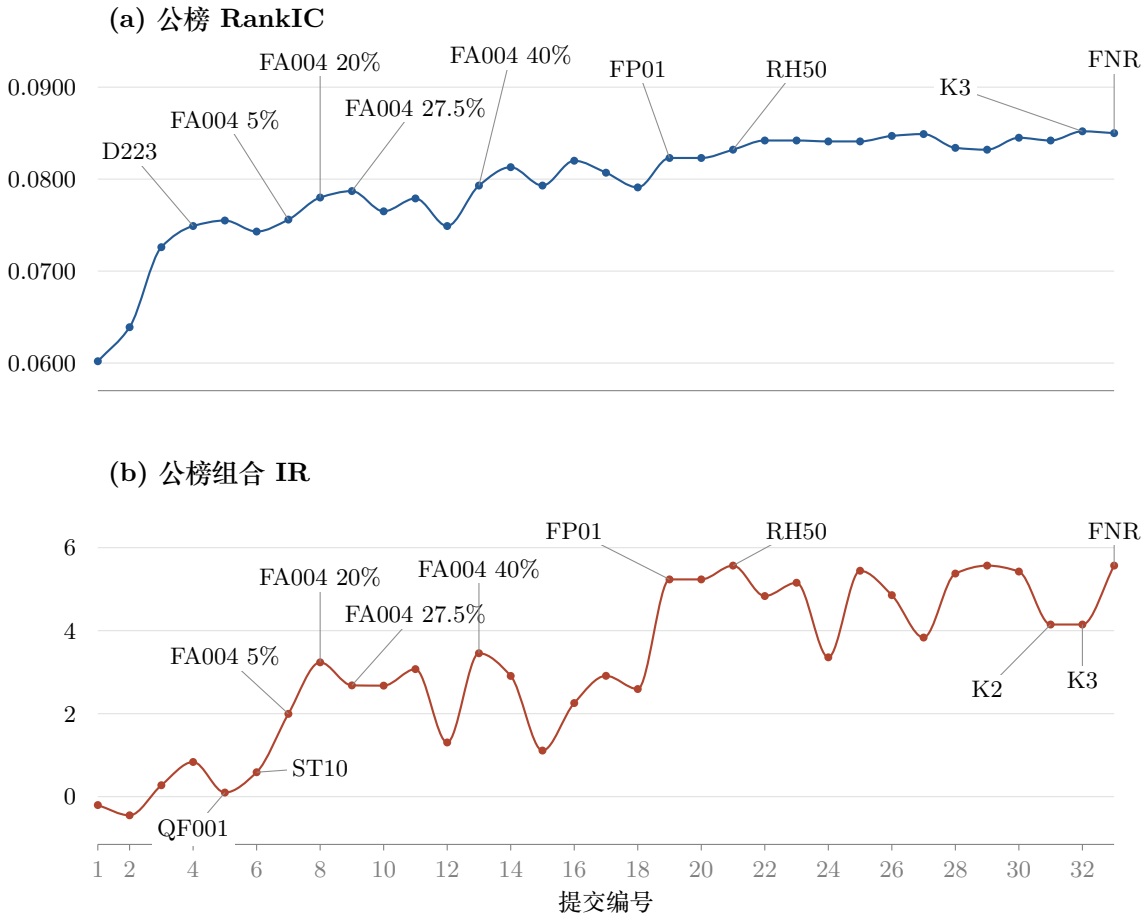


图 7: 历次提交的公榜表现。

表 1: 关键模型的结构、筛选状态与已保存成绩。

提交编号	模型 / 配置	继承关系与主要改动	研究状态	本地 RankIC	年度组合 IR				公榜	
				四年汇总	2019	2020	2021	2022	RankIC	IR
–	M5	在早期 43 特征排名回归模型上增加 20 个历史量价特征，固定 80 棵提升树。	基准对照	0.0486	9.5913	3.5127	3.1239	2.0595	–	–
–	M5+v3/v4	在 M5 上新增市场广度、量价和历史收益因子，模型配置不变。	检验手工因子增益	0.0521	10.1006	3.5725	3.0753	2.4150	–	–
4	D223	在树模型路线中引入表格神经网络，集成排名并修正风格暴露。	后续模型基础	0.0821	8.9213	4.6267	2.7680	2.7104	0.0749	0.8360
5	QF001	D223 加入 3 因子网络，分数划为 25 档；与 ST10、FA004 并行研究。	公榜表现不佳淘汰	0.0826	8.7638	4.7000	2.9708	2.8228	0.0755	0.0997
6	ST10	D223 加入 3 因子网络，以 Student-t 收益分布训练，新信号占 10%。	公榜表现不佳淘汰	0.0834	9.1228	4.5314	2.6587	2.8441	0.0743	0.5892
7	FA004 5%	D223 加入 4 因子网络，因子从当日截面学习，新信号占 5%。	保留，继续改进	0.0827	8.6350	4.8229	2.7701	2.8137	0.0756	1.9957
8	FA004 20%	复用 FA004 5% 的全部组件，仅将辅助权重改为 20%。	保留，扩大权重	0.0839	8.7794	5.0565	2.8307	3.2077	0.0780	3.2373
9	FA004 27.5%	复用 FA004 20% 的全部组件，仅将辅助权重改为 27.5%。	IR 回落	0.0843	–	–	–	–	0.0787	2.6817
13	FA004 40%	复用同一 D223 与因子网络，将辅助权重改为 40%。	后续修正基础	0.0840	7.6335	4.7625	2.5583	3.0726	0.0793	3.4566
19	FP01	基于 FA004 40%，冻结因子网络，新增相似股票之间的相对收益修正。	保留邻域修正	0.0849	–	–	–	–	0.0823	5.2354
21	RH50	在 FP01 上增加约束较弱的修正头，与原头等权组合。	提供最终头部	0.0850	8.2951	4.7434	2.5842	3.2551	0.0832	5.5684
31	K2	以 RH50 的比例微调版为基础，加入 22 维、20 日成熟收益统计校正。	近期校正基准	0.0872	8.8025	4.7551	2.9107	3.5042	0.0842	4.1484
–	AC（未约束）	在 K2 上扩展至 30 维表示并重训修正网络，允许调整全部排名。	年度 IR 恶化淘汰	0.0897	9.5982	5.0703	2.9081	3.0626	–	–
32	K3	沿用 AC 新增信号，保留 K2 前 20% 排名，仅重排其余股票。	提供最终其余排序	0.0892	8.8834	5.4053	2.9850	3.4317	0.0852	4.1484
33	FNR	组合 RH50 与 K3：保留 RH50 前 60 只股票的名单和顺序，以 K3 重排其余股票。	私榜总分第一	0.0887	9.0078	5.3513	2.7407	3.5383	0.0850	5.5684

注：提交编号与图 7 一致。M5 及其手工因子扩展的 RankIC 按年度有效日合并（967 日），IR 为零成本；其余采用连续 RankIC 与单边 5bp 成本。“–”表示未提交或指标缺失。跨阶段标签边界存在差异，增量归因采用同阶段匹配比较；AC 为预测缓存上的筛选结果。来源见 E1–E11。

3.2 固定基准上的输入归因与学习器选择

这一阶段应用第2.4节的匹配比较，先明确增益来自何处。M5 源于早期学习器与特征对照：在 43 个当日特征的 LightGBM 排名回归模型上增加 20 个历史量价特征，形成 63 特征版本。历史特征涵盖收益、波动率、成交活跃度和流动性，最长回看 61 个交易日。模型固定为 80 棵树，目标为下一交易周期收益的截面排名，在多个年度重复训练后，作为因子实验的固定对照。

固定 M5 配置后，新手工因子组合将平均 RankIC 从 0.0486 提高到 0.0521，增量为 0.0035；已有丰富输入的一组扩展带来 0.0104 的增量。前者检验新公式，后者检验已有变量的组合价值。据此，后续工作转向信息表示与模型利用能力。

学习器比较改为固定 347 维输入、排名目标和 24 轮训练。多层感知机、残差网络、TabM 及采用分段线性数值编码的 PLE–TabM，平均 RankIC 分别为 0.0605、0.0547、0.0787 和 0.0802。在这组固定输入、目标和训练轮数的比较中，普通 TabM 含 32160 个参数，少于多层感知机的 53249 个，同时取得更高 RankIC。这提示网络结构可能影响信息利用效率；正则化和优化配置也可能贡献差异，其作用仍需进一步对照。

随后按第2.5节逐级检验训练目标、窗口、平滑及集成配置。D223 由树模型、普通 TabM 和两种 PLE–TabM 组成，再加入中段平滑与风格暴露修正。相对该阶段原有部署配方，保存权重的原始输入确认显示，连续 RankIC 从 0.0806 提高到 0.0821，5bp 成本下的连续 IR 从 3.8784 提高到 4.4771，四个年度的两项指标均改善。这是整套配置的联合增益。

该阶段保存 180 条评价和成本回放记录，其中 25 条被剪枝。对已选配方按年分层、以 20 交易日循环块进行 2000 次配对重采样，RankIC 增量的 95% 条件区间为 $[0.0008, 0.0023]$。这为固定候选的历史增益提供了稳定性诊断，区间未包含此前搜索产生的选择不确定性。

3.3 因子结构筛选与信号利用强度

在 D223 基础上，条件因子网络尝试从当日股票截面学习共同变化，并产生辅助排序。候选按第2.5节先评价部分年份，再决定是否扩展：单因子配置在两个筛选年份均降低 IR 而停止；六因子配置在这两年改善，却在 2019 年未通过 RankIC 门槛；四因子 FA004 通过四年检查，成为保留候选。

QF001、ST10 与 FA004 是同批提出的并行分支。QF001 采用分档输出，ST10 采用 Student-t 收益分布；在这三个候选中，QF001 的本地 IR 最高，ST10 的本地 RankIC 最高，FA004 则在公榜两项指标上均优于二者。据此，后续候选选择以公榜表现为依据，保留 FA004 的表示。这里的公榜反馈参与了候选选择，解释这些结果时需同时考虑网络、训练目标和分数输出方式的差异。

为区分因子信息与利用强度，下一组比较保持 D223 和 FA004 的参数不变，仅调整辅助排名权重。权重从 5% 提高至 20% 时，公榜 RankIC 从 0.0756 升至 0.0780，IR 从 1.9957 升至 3.2373；继续提高至 27.5% 后，RankIC 上升而 IR 回落。40% 版本的公榜 IR 达到 3.4566，但权重更高的 60% 版本两项指标均低于 40% 版本。由此，研究保留已有效的因子表示，将后续重点转向信息使用方式与训练目标。

3.4 冻结表示下的邻域修正与解冻对照

这一阶段应用第2.6节的受限增量训练。FP01 以 FA004 40% 为参考，冻结原因子网络，以因子方差缩放的个股因子暴露与 Barra 风险特征，共同定义股票间距离，为每只股票选择 24 个近邻。新增网络综合自身、邻域均值及两者差值，学习相近股票之间的相对收益。

修正网络仅含 2049 个参数，输出层零初始化，中心化前用 $0.05\tanh(\cdot)$ 限幅；训练目标为

式(7)，由排名误差、保持惩罚和邻域配对损失组成。固定基础集成和 40% 辅助权重，使新增模块从原预测出发，检验局部相对收益信息的价值。

匹配对照比较了仅用 Barra 定义邻域和加入因子暴露距离两种配置。加入因子暴露距离后，连续 RankIC 从 0.0847 升至 0.0849，四个年度中三个改善。与同阶段原 FA004 参考相比，FP01 的 RankIC 增量为 0.0009。FP01 的公榜 RankIC 为 0.0823、IR 为 5.2354，均高于原 40% 版本。该阶段的本地筛选依据 RankIC 与配对诊断，组合 IR 证据来自公榜反馈。

RH50 保留这套表示和邻域方法，增加保持惩罚较弱的第二个修正头，与原头等权组合。其本地 RankIC 达到 0.0850，公榜为 0.0832/5.5684。相对于继续放大原信号权重，这组结果支持通过小规模重训改善因子信息的利用方式。

为检验冻结范围是否限制了增益，还实施了分层及全参数解冻。各候选重新生成年度表示与邻域，再重训两个修正头，融合比例固定。分层候选中，仅有一个通过 2022 年初筛并扩展至 2020、2021 年，但三年平均 RankIC 增量为 0.0002，低于预设 0.0005 门槛；六个全参数候选均因 2022 年回退超过 0.0002 而停止。这些对照使研究继续保留有效表示，转向近期信息校正。

3.5 已实现收益统计与排序范围约束

K2 将第2.7节的近期校正应用于 RH50 的双头比例微调版本。每次预测使用最近 20 个标签已成熟的收益截面，信号日期为 $t-21,\ldots,t-2$；最近标签在 t 日开盘时已实现。22 维特征、先验系数、正则化参数、时间衰减和输出限幅均在离线阶段固定，式(8)根据当前窗口生成临时修正。K2 的本地 RankIC 达到 0.0872，公榜 RankIC 为 0.0842，但公榜 IR 降至 4.1484，排序精度与组合 IR 在这一版本中出现分离，汇总指标尚不足以确定其中的持仓或成本原因。

后续候选 AC 在原 22 维表示之外加入 8 维冻结神经摘要，并重训使用 178 维上下文的修正网络。本地 RankIC 升至 0.0897，但 2022 年 IR 较 K2 下降 0.4417，超过该轮允许的 0.10 回退。按照第2.5节的联合门槛，该候选被淘汰；另一个达到 RankIC 增量要求的配置也因 2021 年 IR 下降约 0.330 被舍弃。

K3 保留 AC 新增信号，以 K2 为排序参照，仅重排后 80% 股票，前 20% 名单与顺序保持。原始输入复算后，连续 RankIC 为 0.0892，相对 K2 增加 0.0020；四年 IR 中三个提高，2022 年下降 0.0726，满足当轮回退限制。公榜 RankIC 升至 0.0852，IR 仍为 4.1484。在本地评价下，排序范围约束保留了排序增量，并将年度 IR 回退控制在设定门槛内；公榜结果促使后续重新选择头部参照。

3.6 最终组合与部署确认

FNR 进一步将排序参照改为 RH50：保留其前 60 只股票的名单与顺序，以 K3 重排其余 240 只。该改动对应第2.7节的排序范围约束，检验新增信号在参考头部之外的价值。表2给出固定成本与组合设置下的匹配结果，连续 RankIC 覆盖 970 个有效日期。

表 2: 本地开发区间比较，所有列采用相同评价口径。

指标	RH50 参考	K3 窗口增强	FNR
连续 Mean RankIC	0.0850	0.0892	0.0887
2019 年 IR	8.2951	8.8834	9.0078
2020 年 IR	4.7434	5.4053	5.3513
2021 年 IR	2.5842	2.9850	2.7407
2022 年 IR	3.2551	3.4317	3.5383

相对 RH50，FNR 的 RankIC 提高 0.0037，四个年度 IR 均提高；相对 K3，RankIC 减少 0.0005，年度 IR 有升有降。FNR 的公榜 RankIC 为 0.0850，较 K3 降低 0.0002；IR 为 5.5684，较 K3 提高 1.4200，与 RH50 相同。固定外层头部、去掉内层保护的另一项消融使 RankIC 略降，三个年度 IR 提高、一个下降，说明内层保护的独立作用仍需进一步检验。

部署确认遵循第2.8节：逐年加载保存权重，从当前许可历史窗口重建特征与预测，以原始输入复算值报告 K3 及 FNR 的结果。在 2019 年 12 月 31 日、2021 年 6 月 15 日、2022 年 5 月 6 日和 2022 年 12 月 30 日这 4 个交易日，各核对 300 只股票，共 1200 个股票-日预测分数，均与参考数值完全一致。这些检查将统计改进与实际部署模型对应起来。

3.7 公私榜评价与结论范围

表3报告固定方案的公私榜成绩。公榜参与了上述候选选择，私榜是在最终版本固定后获得的额外评价。FNR 在官方榜单中的公榜总成绩排名第 2，私榜总成绩排名第 1。公榜成绩经提交记录核验，私榜成绩来自参赛反馈；平台未披露隐藏日期、逐日收益、持仓及完整组合设置。

表 3: FNR 的隐藏评价反馈。差值为私榜减公榜；相对变化以公榜为分母。

指标	公榜	私榜	绝对变化	相对变化
Mean RankIC	0.0850	0.0825	−0.0025	−2.94%
组合 IR	5.5684	5.2132	−0.3552	−6.38%
总成绩排名	2	1	–	–

私榜 RankIC 为公榜的 97.06%，IR 为 93.62%，给出了 FNR 在本次隐藏评价中的表现。指标差异同时包含时期、样本组成、评价设置、随机波动和模型选择的影响；相对回落用于描述两次评价的差异，选择偏差的份额仍需更完整的数据与独立对照估计。

4 抗过拟合机制的解释与边界

4.1 证据与机制解释

表 4: 关于有效性的结论分级。

证据层级	主要内容	适用范围
直接观测	标签边界检查、匹配结果、候选淘汰、输入一致性、公私榜成绩。	已记录的实验、被测输入和对应评价区间。
机制解释	跨年筛选约束单年偏好；收缩限制噪声响应；异构集成利用误差差异。	对设计作用的合理解释，独立收益仍待匹配消融。
待验证贡献	搜索策略的净收益、选择偏差大小、各模块的独立贡献。	需要流程对照、额外隐藏区间与重复实验。

信息隔离 标签时间边界、训练期统计与历史成员处理，使模型训练和评价遵循当时可用的信息。信息隔离建立了可信比较的基础，反复选择带来的偏差则需要由额外评价检验。

跨年比较 跨年比较要求候选同时适应多个时期，减少选择对某段特殊行情的依赖。各年份共享市场结构且被反复观察，因此仍存在样本相关性和选择偏差；较弱年份初筛的主要收益是节省计算。

保留长期信息 冻结基座、小型修正、保持惩罚和限幅，使新增模型倾向于在既有预测附近学习；近期回归以固定先验和低维统计约束调节适应幅度。这些设计在保留长期信息与吸收近期变化之间折中。参考模型失效时，较强的保持约束也可能延缓纠正。

实现一致性 权重重载和原始输入复算用于定位实现偏差，使研究与部署评价同一预测器。它们与按时间验证互为补充：前者确认实现一致，后者检验预测效果。

4.2 验证局限与后续检验

本地年份与公榜均被反复用于开发，FNR 经历了自适应选择。当前证据主要来自固定随机种子的年度比较、神经网络在两个额外随机种子（17、123）下的局部检查和一次私榜评价。后续需通过嵌套验证、多重比较校正与多种子检验，量化选择偏差与训练波动。

现有结果支持 FNR 在该任务上的有效性。若要进一步估计研究流程本身的贡献，需要在相近数据和计算预算下比较不同搜索策略，再将各自选出的方案交给共同的独立评价区间。

4.3 可迁移的研究原则

可迁移的实践是为每个候选明确参考对象、比较条件、有效时期与接受门槛，使搜索方向能够灵活调整，接受改动的依据仍可复核。

后续研究可在新增时间区间前固定模型与主要假设，保存逐日预测、成本、持仓及收益，并采用按日期分块的自助法估计不确定性。结构约束采用匹配消融，搜索策略采用独立评价。私榜反馈一旦用于下一轮改动，即纳入开发数据，并另设最终评价区间。

5 结论

本文从沪深 300 截面预测研究中归纳了四项相互配合的方法：按标签成熟时间隔离训练样本，以跨年匹配比较评价增量，逐级筛选候选，以及通过受限修正和原始输入复算连接训练与部署。FNR 在公榜取得 RankIC 0.0850、IR 5.5684，总成绩排名第 2；在私榜取得 RankIC 0.0825、IR 5.2132，总成绩排名第 1。

候选淘汰记录表明，这套流程可执行、可复核；私榜结果提供了 FNR 在该隐藏区间的评价证据。各项机制的一般有效性、独立贡献和选择偏差大小，仍需更严格的对照检验。后续工作的重点是将这一研究流程用于新的时间区间，在固定方案后积累更多独立证据。

参考文献

[1] Cawley G C, Talbot N L C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. *Journal of Machine Learning Research*, 11:2079–2107, 2010. 出版方全文.

[2] Dwork C, Feldman V, Hardt M, et al. Preserving Statistical Validity in Adaptive Data Analysis. *Proceedings of the 47th Annual ACM Symposium on Theory of Computing*, 117–126, 2015. arXiv:1411.2664.

[3] Li L, Jamieson K, DeSalvo G, et al. Hyperband: A Novel Bandit-Based Approach to Hyperparameter Optimization. *Journal of Machine Learning Research*, 18(185):1–52, 2018. 出版方全文.

[4] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30, 2017. 原文.

[5] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling. *International Conference on Learning Representations*, 2025. arXiv:2410.24210.

[6] Hoerl A E, Kennard R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1):55–67, 1970. doi:10.1080/00401706.1970.10488634.

[7] Burges C, Shaked T, Renshaw E, et al. Learning to Rank Using Gradient Descent. *Proceedings of the 22nd International Conference on Machine Learning*, 89–96, 2005. doi:10.1145/1102351.1102363.

[8] HenryZ16. *skd-backtest*: 面向指数增强研究的日频 Python 回测框架 [软件]. https://github.com/HenryZ16/skd-backtest（访问日期：2026 年 10 月 17 日）。

A 证据来源与复核范围

本文数值来自保存的研究材料。证据副本位于发布目录的writeups_aux/search_methodology/中，evidence/index.json 列出原文件与发布副本的 SHA-256 校验值及处理范围。以下证据路径均相对于该附件目录。表5给出主要证据映射，具体实验范围以对应记录为准。

公榜数据于 2026 年 10 月 16 日从比赛提交记录核验，整理后的提交成绩绘图数据随文保存；私榜数据来自参赛者反馈。原始实验材料支持任务内结果，参考文献提供一般方法背景。

表 5: 主要事实的证据映射，完整路径见补充索引。

编号	材料	本文使用范围
E1	原始复现说明与回测实现	年度向前训练、标签边界、换手约束及统计诊断。
E2	固定 M5 因子归因报告	手工公式、丰富输入和学习表示的贡献区分。
E3	神经网络实际实验记录	匹配输入与轮数的架构结果及参数量。
E4	D223 最终研究报告	实际搜索与剪枝、成本情景、条件重采样结果。
E5	条件因子容量与正则报告	因子数、宽度与跨年晋级的实际比较。
E6	邻域重构训练记录	2049 参数修正头、保持惩罚与匹配对照。
E7	分层与全参数解冻记录	可训练范围、重建预测缓存、年度筛选及停止结果。
E8	K3 原始窗口确认报告	高分候选的回退、最终统计增强及缓存差异。
E9	头部保持及消融结果	最终年度表现与保护机制的不确定性。
E10	最终审计和参赛反馈	有限输入一致性、最终公私榜点估计。
E11	提交成绩记录	按原始文件编号记录公榜 RankIC 与 IR。